AirSentinel Cameroun

Système d'aide à la décision sanitaire basé sur l'intelligence artificielle

Surveillance et prédiction de la qualité de l'air pour 40 villes camerounaises

Rapport Technique

Hackathon IndabaX Cameroon 2026

BODEHOU Sabine	ISSEA Yaoundé
FANKAM Marc Aurel	ISSEA Yaoundé
PEURBAR RIMBAR Firmin	ISSEA Yaoundé
FOFACK ALEMDJOU Henri Joël	ENSP Yaoundé

Équipe DPA Green Tech | Avril 2026 | Yaoundé, Cameroun

Table des matières

Table des figures **4**

Liste des tableaux **5**

Résumé **6**

1 Introduction **7**
1.1 Contexte et problématique 7
1.2 Objectifs 7
1.3 Contributions 8
1.4 Organisation du rapport 8

2 Données et pipeline de collecte **9**
2.1 Source des données 9
2.2 Couverture géographique et zonage climatique 9
2.3 Statistiques descriptives 10
2.4 Pipeline de mise à jour automatique 11

3 Méthodologie **12**
3.1 Feature engineering 12
3.1.1 Variables temporelles et saisonnières 12
3.1.2 Variables de mémoire : lags et fenêtres glissantes 12
3.1.3 Variables d'épisodes climatiques 12
3.1.4 Variables régionales 12
3.2 Indice de Risque Sanitaire par ACP 13
3.2.1 Motivation 13
3.2.2 Résultats de l'ACP 13
3.2.3 Calcul et normalisation 13
3.3 Modèle hybride Régression Linéaire + ARIMA 14
3.3.1 Justification de l'approche hybride 14
3.3.2 Architecture 14
3.3.3 Séparation entraînement / test 15

4 Résultats et évaluation **16**
4.1 Performances globales 16
4.2 Analyse graphique des prédictions 16
4.2.1 Cas de validation : Bertoua, 13 février 2025 17
4.3 Diagnostic des résidus 17
4.3.1 Distribution et structure temporelle 17

4.3.2 Autocorrélation des résidus ARIMA 17
4.4 Interprétabilité SHAP 18
4.4.1 Importance globale des variables 18
4.4.2 Analyse directionnelle 19
4.4.3 Analyse par zone climatique 19

5 Architecture de la plateforme 21
5.1 Vue d'ensemble 21
5.2 Dashboard Streamlit 21
5.3 API FastAPI 22
5.4 Seuils contextuels camerounais 22

6 Conclusion et perspectives 23
6.1 Bilan 23
6.2 Limitations 23
6.3 Perspectives 23

Références bibliographiques 24

Table des figures

2.1 Heatmap des corrélations de Spearman — AirSentinel Cameroun 11

3.1 Régression seule vs modèle hybride RL+ARIMA — Yaoundé, 60 premiers jours 2025 14
3.2 Architecture du modèle hybride Régression Linéaire + ARIMA 15

4.1 Prédictions vs observations — modèle hybride RL+ARIMA ($R^2 = 0{,}893$, MAE $= 3{,}456\,\mu\text{g/m}^3$) 16
4.2 Diagnostic des résidus — distribution, QQ-Plot et série temporelle . . . 17
4.3 ACF et PACF des résidus ARIMA — Yaoundé (zone équatoriale) . . . 18
4.4 Importance SHAP moyenne des variables — AirSentinel Cameroun . . 18
4.5 Beeswarm plot SHAP — direction et magnitude des contributions . . . 19
4.6 Top 3 des variables SHAP par zone climatique INS Cameroun (2019) . 20

Liste des tableaux

2.1 Répartition des 40 villes par zone climatique 9
2.2 Statistiques descriptives des variables principales (N = 53 520) 10

3.1 Variance expliquée par les composantes principales de l'IRS 13

4.1 Performances du modèle hybride RL+ARIMA vs baseline (données test 2025–2026) 16

5.1 Description des 6 blocs fonctionnels du dashboard 21
5.2 Endpoints de l'API publique AirSentinel 22

Résumé

AirSentinel Cameroun est un système intégré de surveillance, de prédiction et d'aide à la décision sanitaire pour la qualité de l'air, développé dans le cadre du Hackathon IndabaX Cameroon 2026 par l'équipe DPA Green Tech (ISSEA / ENSP Yaoundé). Face à l'absence totale de systèmes d'alerte opérationnels et au dépassement chronique du seuil directeur de l'OMS pour les $PM_{2.5}$ ($15\,\mu g/m^3$) dans 94 % des villes camerounaises, ce projet propose une solution entièrement automatisée, à coût nul, couvrant 40 villes et 10 régions sur la période août 2022 – avril 2026 (53 520 observations journalières).

Le système repose sur un **modèle hybride Régression Linéaire + ARIMA**, décliné par zone climatique selon la nomenclature de l'Institut National de la Statistique du Cameroun (INS, 2019). Ce modèle atteint un coefficient de détermination $R^2 = 0{,}893$ avec une erreur absolue moyenne MAE $= 3{,}456\,\mu g/m^3$, soit une réduction de 70,3 % par rapport à la baseline naïve. L'interprétabilité est assurée par une analyse SHAP exhaustive, qui révèle la prédominance des variables de mémoire du $PM_{2.5}$ dans tous les profils de prédiction.

Un **Indice de Risque Sanitaire (IRS)**, calculé par Analyse en Composantes Principales sur cinq polluants et normalisé entre 0 et 1, synthétise l'exposition multidimensionnelle. Des seuils contextuels, calibrés sur les percentiles historiques par ville, complètent le référentiel OMS pour une alerte adaptée aux réalités camerounaises.

La plateforme comprend un dashboard Streamlit en six blocs, une API FastAPI publique (7 endpoints REST) et une application mobile progressive (PWA), tous hébergés gratuitement.

Mots-clés : qualité de l'air, $PM_{2.5}$, modèle hybride, ARIMA, régression linéaire, analyse en composantes principales, SHAP, Cameroun, santé publique, IndabaX 2026.

1. Introduction

1.1 Contexte et problématique

La pollution atmosphérique constitue le principal risque environnemental pour la santé humaine à l'échelle mondiale. Les particules fines $PM_{2.5}$ — dont le diamètre aérodynamique est inférieur à 2,5 micromètres — pénètrent profondément dans l'appareil respiratoire et constituent le polluant atmosphérique le plus néfaste selon les critères de l'OMS. Chen & Hoek (2020) établissent, dans une méta-analyse portant sur plus de 70 études épidémiologiques, une augmentation de la mortalité cardio-respiratoire de 6 % par incrément de 10 μg/m^{3}d'exposition chronique.

Au Cameroun, 94 % des villes dépassent le seuil directeur annuel de l'OMS fixé à 15 μg/m^3(WHO AQG 2021, NCBI NBK574591). Les sources de pollution sont multiples et géographiquement différenciées. Dans la zone soudano-sahélienne (Extrême-Nord), le transport de poussières sahariennes par l'harmattan constitue la source dominante, avec des concentrations de $PM_{2.5}$ dépassant régulièrement 50 μg/m^{3}en saison sèche (Schepanski *et al.*, 2007 ; Knippertz & Todd, 2008). Dans la zone équatoriale, les feux de brousse de saison sèche (janvier à mars) génèrent des pics de $PM_{2.5}$ pouvant dépasser 100 μg/m^3, liés à la combustion de biomasse (Gordon *et al.*, 2023 ; Barker *et al.*, 2020). La zone soudanienne est quant à elle affectée par la combinaison du dust sahélien et des inversions thermiques nocturnes.

Face à ce constat, aucun système opérationnel de surveillance en temps réel ni d'alerte précoce n'existait au Cameroun avant ce projet. Les 27 millions de Camerounais étaient exposés sans information ni recommandation sanitaire adaptée à leur contexte local.

1.2 Objectifs

AirSentinel Cameroun poursuit trois objectifs stratégiques complémentaires :

OS1 — Surveiller
: Mettre en place un pipeline de collecte quotidienne automatisé pour 40 villes et 10 régions, alimenté par l'API Open-Meteo (gratuite, sans clé), avec mise à jour via GitHub Actions.

OS2 — Prédire
: Développer un modèle hybride Régression Linéaire + ARIMA, décliné par zone climatique INS, permettant des prévisions $PM_{2.5}$ à horizon 24, 48 et 72 heures.

OS3 — Décider
: Générer des recommandations sanitaires contextualisées par profil, en s'appuyant sur un Indice de Risque Sanitaire multidimensionnel et des seuils calibrés sur les données historiques camerounaises.

1.3 Contributions

Ce projet apporte les contributions suivantes :

(1) Un dataset inédit de 53 520 observations journalières sur 40 villes camerounaises (août 2022 – avril 2026), construit à partir de données librement accessibles.
(2) Un modèle hybride RL+ARIMA intégrant la saisonnalité et les spécificités climatiques des trois zones géographiques camerounaises, avec $R^2 = 0{,}893$.
(3) Une analyse d'interprétabilité SHAP complète révélant les déterminants climatiques du $PM_{2.5}$ au Cameroun.
(4) Un Indice de Risque Sanitaire (IRS) multivariable calculé par ACP, normalisé et décliné en quatre niveaux d'alerte calibrés sur l'historique local.
(5) Une plateforme intégrée (dashboard + API + PWA) à coût d'exploitation nul.

1.4 Organisation du rapport

Le chapitre 2 décrit le dataset et le pipeline de collecte. Le chapitre 3 présente la méthodologie : feature engineering, IRS par ACP et modèle hybride. Le chapitre 4 analyse les performances et l'interprétabilité SHAP. Le chapitre 5 décrit l'architecture de la plateforme. Le chapitre 6 conclut et ouvre des perspectives.

2. Données et pipeline de collecte

2.1 Source des données

Les données sont collectées quotidiennement via l'**API Open-Meteo**, une source gratuite et sans authentification, proposant des données météorologiques journalières et des concentrations de polluants atmosphériques (agrégées depuis l'horaire) pour toute coordonnée géographique. Ce choix garantit la reproductibilité et la pérennité du système sans contrainte budgétaire.

Deux catégories de variables sont collectées pour chacune des 40 villes. Les **variables météorologiques** (20 variables journalières) incluent les températures maximale, minimale et moyenne, la somme des précipitations, la vitesse maximale du vent à 10 m, les heures d'ensoleillement, le rayonnement solaire à ondes courtes et l'évapotranspiration de référence FAO-56. Les **variables de pollution** (15 variables, agrégées depuis l'horaire) comprennent les concentrations moyennes et maximales de $PM_{2.5}$, PM_{10}, NO_2, SO_2, O_3, CO, poussières et UV, ainsi que les indices AQI américains correspondants.

2.2 Couverture géographique et zonage climatique

Les 40 villes retenues couvrent l'ensemble du territoire camerounais, réparties selon le zonage climatique de l'INS Cameroun (2019) en trois zones écologiques distinctes. Ce zonage, fondé sur les régimes pluviométriques et les caractéristiques végétales, conditionne directement les sources et les niveaux de pollution.

Tableau 2.1. Répartition des 40 villes par zone climatique

Zone climatique	Régions	Villes	Facteurs de pollution dominants
Zone équatoriale	Centre, Est, Sud, Littoral, Sud-Ouest, Ouest, Nord-Ouest	28	Feux de brousse (jan.–mars), combustion de biomasse
Zone soudanienne	Adamaoua, Nord	8	Dust sahélien, inversions thermiques nocturnes
Zone soudano-sahélienne	Extrême-Nord	4	Poussières sahariennes (harmattan), dust dominant
Total	**10 régions**	**40**	

Source : Auteurs à partir des données de lÁPI Open-Meteo.

2.3 Statistiques descriptives

Le dataset final comprend **53 520 observations** journalières couvrant la période août 2022 – avril 2026. Le tableau 2.2 présente les statistiques descriptives des variables principales.

Tableau 2.2. Statistiques descriptives des variables principales (N = 53 520)

Variable	Moy.	Méd.	Éc.-T.	Min	Max	p90
$PM_{2.5}$ moyen (μg/m^3)	21,4	16,8	17,2	0,5	134,4	42,1
Dust moyen (μg/m^3)	42,3	18,1	68,4	0,0	891,3	113,2
Temp. max. (°C)	30,9	31,2	4,8	16,4	46,8	36,7
Précipitations (mm)	3,8	0,4	9,1	0,0	98,7	12,4
Vent max. (km/h)	18,7	17,4	8,3	4,0	71,3	28,1
IRS (normalisé 0–1)	0,162	0,095	0,189	0,000	1,000	0,411

Source : Auteurs à partir des données de lÁPI Open-Meteo.

La figure 2.1 présente la heatmap des corrélations de Spearman entre l'ensemble des variables du dataset. On distingue nettement deux blocs structurants : (1) un bloc météorologique regroupant les variables de température, fortement inter-corrélées ($\rho > 0{,}90$) ; (2) un bloc polluants regroupant $PM_{2.5}$, PM_{10}, dust et CO ($\rho > 0{,}70$). Les précipitations présentent une corrélation négative significative avec le $PM_{2.5}$ ($\rho \approx -0{,}40$), confirmant leur rôle de lessivage atmosphérique. Cette structure justifie l'ACP pour la construction de l'IRS (section 3.2).

Figure 2.1. Heatmap des corrélations de Spearman — AirSentinel Cameroun

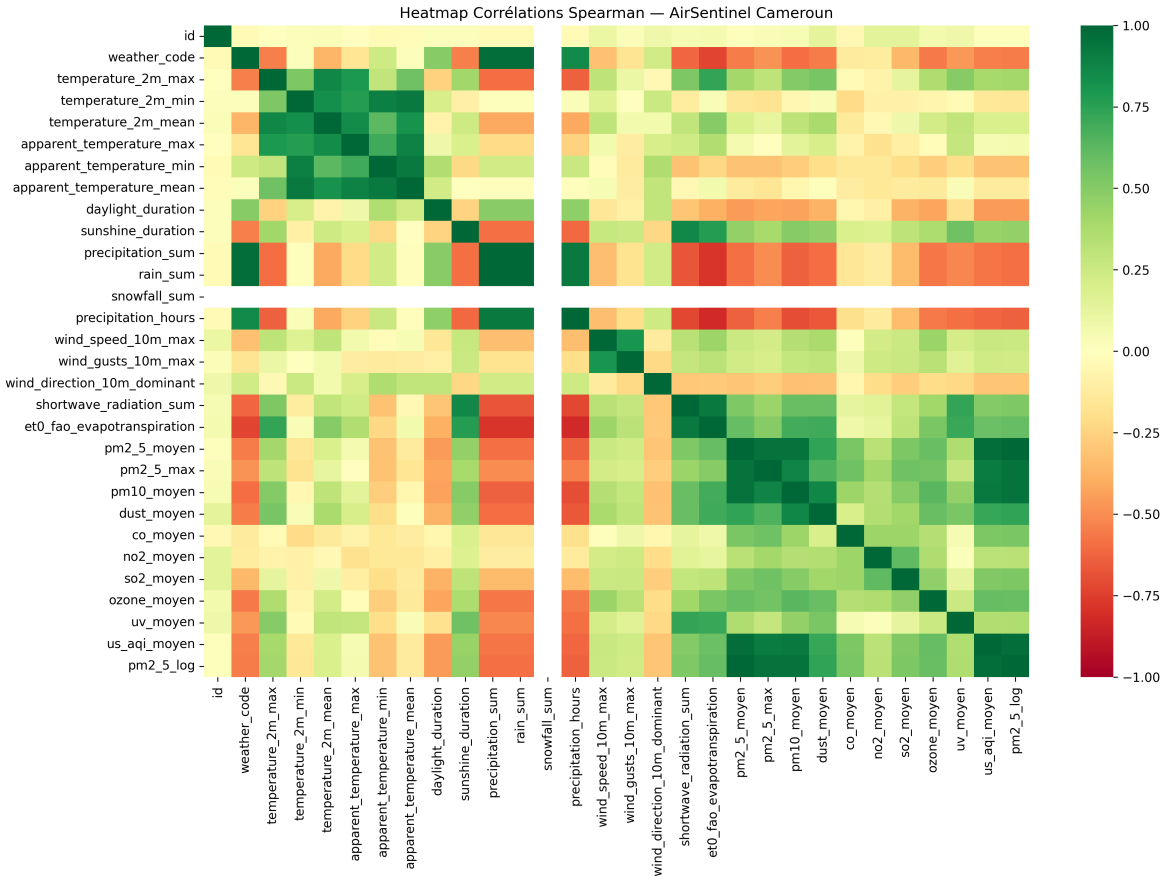

Source : Auteurs à partir des données de l'API Open-Meteo.

2.4 Pipeline de mise à jour automatique

La collecte quotidienne est automatisée via **GitHub Actions**. Le workflow `update_daily.yml` s'exécute chaque jour à 03h00 UTC (04h00 WAT). Il télécharge les données de la veille pour les 40 villes (avec 6 secondes de délai entre chaque requête pour respecter les limites de l'API), recalcule les variables dérivées et les features, met à jour l'IRS en utilisant les paramètres ACP sauvegardés (`pca_irs.pkl`, `scaler_acp_irs.pkl`), et commite automatiquement le fichier Parquet mis à jour.

En cas d'indisponibilité des paramètres ACP, un fallback `IRS_brut / 5.0` assure la continuité du service. Le niveau sanitaire (`niveau_sanitaire`) est calculé indépendamment sur la base du $PM_{2.5}$ et des seuils OMS (IT1 à IT4).

3. Méthodologie

3.1 Feature engineering

3.1.1 Variables temporelles et saisonnières

La nature temporelle du $PM_{2.5}$ impose de capturer explicitement les effets saisonniers. Trois catégories de variables temporelles sont dérivées. L'année, le mois et le jour de l'année ($j \in [1, 366]$) permettent au modèle de capturer la position dans le cycle annuel. Un code saison binaire encode la saison sèche (0, novembre–mars) et la saison des pluies (1, avril–octobre) selon la nomenclature INS Cameroun (2019). L'analyse SHAP ultérieure confirme que `jour_annee` constitue la variable temporelle la plus contributive.

3.1.2 Variables de mémoire : lags et fenêtres glissantes

La persistance temporelle du $PM_{2.5}$ — un épisode de pollution pouvant durer plusieurs jours — est capturée par cinq variables de mémoire :

$$x_{t,\ell_1} = \mathrm{PM}_{2.5}(t-1) \qquad x_{t,\ell_3} = \mathrm{PM}_{2.5}(t-3) \qquad x_{t,\ell_7} = \mathrm{PM}_{2.5}(t-7) \tag{3.1}$$

$$x_{t,m_7} = \frac{1}{7}\sum_{k=1}^{7} \mathrm{PM}_{2.5}(t-k) \quad x_{t,m_{30}} = \frac{1}{30}\sum_{k=1}^{30} \mathrm{PM}_{2.5}(t-k) \tag{3.2}$$

L'analyse SHAP (section 4.4) révèle que ces cinq variables constituent les premières positions du classement d'importance, validant cette approche de feature engineering.

3.1.3 Variables d'épisodes climatiques

Deux variables binaires encodent les épisodes climatiques associés à des pics de pollution. L'épisode harmattan intense est défini par la conjonction d'un dust supérieur au $Q_{90}(\mathrm{dust}_{\text{région}})$ et de précipitations inférieures au $Q_{10}(\mathrm{précip}_{\text{région}})$. L'épisode feux de brousse est défini par un CO supérieur au $Q_{90}(\mathrm{CO}_{\text{saison sèche, région}})$. L'utilisation de seuils régionaux plutôt que nationaux évite le biais lié aux niveaux de base très différents selon les zones.

3.1.4 Variables régionales

Dix variables indicatrices encodent la région d'appartenance de chaque ville, permettant au modèle de régression de capturer des effets fixes régionaux. La variable `longitude` apparaît également dans le top 15 des features SHAP, reflétant le gradient est-ouest de pollution lié à la proximité du Sahara.

3.2 Indice de Risque Sanitaire par ACP

3.2.1 Motivation

L'exposition aux polluants atmosphériques est intrinsèquement multidimensionnelle. Une mesure synthétique est nécessaire pour résumer le risque sanitaire global en un seul indicateur opérationnel. L'Analyse en Composantes Principales est retenue pour trois raisons : réduction de dimensionnalité, élimination de la multicolinéarité entre polluants (visible sur la figure 2.1), et production d'un indice normalisé interprétable.

Les cinq variables retenues pour l'ACP sont le $PM_{2.5}$ moyen, le dust moyen, le CO moyen, l'UV moyen et l'ozone moyen. Ces variables couvrent les principaux vecteurs d'impact sanitaire identifiés dans la littérature (WHO AQG 2021).

3.2.2 Résultats de l'ACP

Tableau 3.1. Variance expliquée par les composantes principales de l'IRS

Composante	Valeur propre	Variance expliquée	Cumulée
PC1	2,754	55,1 %	55,1 %
PC2	1,401	28,0 %	83,1 %
PC3	0,521	10,4 %	93,5 %
Seuil retenu : 2 composantes		83,1 %	

Source : Auteurs à partir des données de lÁPI Open-Meteo.

Deux composantes expliquent 83,1 % de la variance totale, satisfaisant largement le critère de Kaiser ($\lambda > 1$). La troisième composante ($\lambda = 0{,}521$) est ignorée.

3.2.3 Calcul et normalisation

L'IRS brut est calculé comme combinaison linéaire pondérée par la variance expliquée :

$$\mathrm{IRS}_{\mathrm{brut}} = \frac{\lambda_1 \cdot \mathrm{PC}_1 + \lambda_2 \cdot \mathrm{PC}_2}{\lambda_1 + \lambda_2}, \qquad \lambda_1 = 0{,}551, \quad \lambda_2 = 0{,}280 \tag{3.3}$$

La normalisation min-max ramène l'IRS dans l'intervalle $[0, 1]$:

$$\mathrm{IRS} = \frac{\mathrm{IRS}_{\mathrm{brut}} - \mathrm{IRS}_{\mathrm{min}}}{\mathrm{IRS}_{\mathrm{max}} - \mathrm{IRS}_{\mathrm{min}}} \in [0, 1] \tag{3.4}$$

Les niveaux d'alerte sont définis par les percentiles historiques du dataset :

$$\mathrm{Niveau}(\mathrm{IRS}) = \begin{cases} \text{FAIBLE} & \text{si } \mathrm{IRS} < p_{50} \\ \text{MODÉRÉ} & \text{si } p_{50} \leq \mathrm{IRS} < p_{75} \\ \text{ÉLEVÉ} & \text{si } p_{75} \leq \mathrm{IRS} < p_{90} \\ \text{CRITIQUE} & \text{si } \mathrm{IRS} \geq p_{90} \end{cases} \tag{3.5}$$

Cette approche relative aux données camerounaises — plutôt qu'aux standards internationaux — permet d'identifier les jours anormalement risqués dans le contexte local. Elle est complétée par les seuils contextuels p90 par ville (section 5.4).

3.3 Modèle hybride Régression Linéaire + ARIMA

3.3.1 Justification de l'approche hybride

La figure 3.1 illustre l'apport du composant ARIMA sur les 60 premiers jours de 2025 à Yaoundé. Le modèle hybride suit plus fidèlement les variations journalières du $PM_{2.5}$ réel que la régression seule, en particulier lors des transitions rapides (semaine du 20 janvier) et des pics de fin février. Cet apport provient de la correction des résidus auto-corrélés de la régression par le composant ARIMA.

Figure 3.1. Régression seule vs modèle hybride RL+ARIMA — Yaoundé, 60 premiers jours 2025

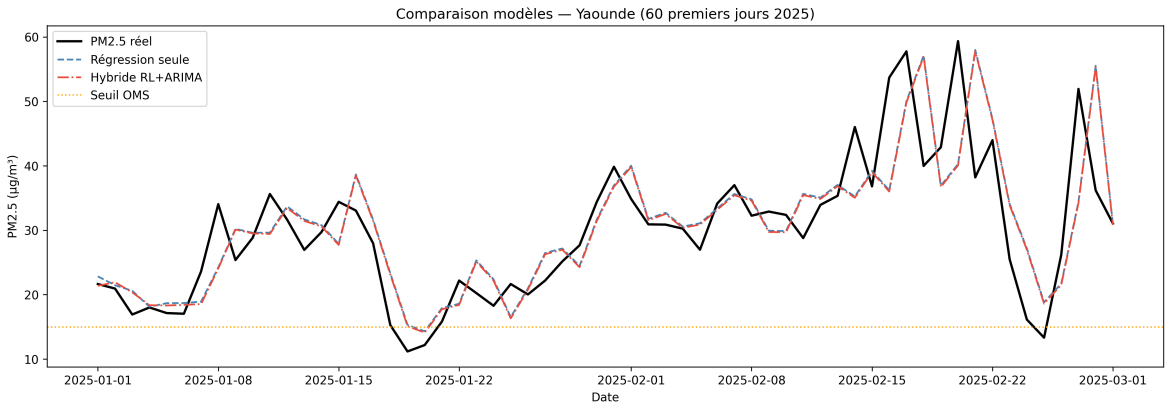

Source : Auteurs à partir des données de l'API Open-Meteo.

3.3.2 Architecture

Le modèle hybride combine deux composantes complémentaires. Premièrement, un modèle de **régression linéaire multiple** capture les relations entre le $PM_{2.5}$ et l'ensemble des features météorologiques, temporelles et régionales. Les résidus $\hat{\varepsilon}_t = y_t - \hat{y}_t^{\mathrm{RL}}$ sont ensuite analysés par zone climatique. Deuxièmement, un modèle **ARIMA** distinct est ajusté sur ces résidus pour chacune des trois zones, capturant la dépendance temporelle résiduelle spécifique à chaque contexte climatique (Box & Jenkins, 1976). La prédiction finale à l'horizon h est :

$$\hat{y}_{t+h} = \hat{y}_{t+h}^{\mathrm{RL}} + \hat{\varepsilon}_{t+h}^{\mathrm{ARIMA}} \tag{3.6}$$

Figure 3.2. Architecture du modèle hybride Régression Linéaire + ARIMA

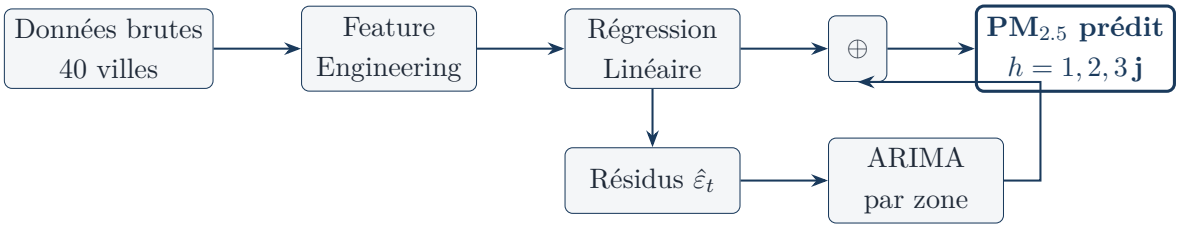

Source : Auteurs à partir des données de l'API Open-Meteo.

3.3.3 Séparation entraînement / test

La séparation chronologique est indispensable pour éviter toute fuite d'information. La frontière est fixée au 1er janvier 2025 : la période août 2022 – décembre 2024 constitue l'ensemble d'entraînement ($\approx 80\,\%$) et la période janvier 2025 – avril 2026 l'ensemble de test ($\approx 20\,\%$). Les variables de lag et de moyennes glissantes sont recalculées en respectant scrupuleusement cette frontière.

4. Résultats et évaluation

4.1 Performances globales

Tableau 4.1. Performances du modèle hybride RL+ARIMA vs baseline (données test 2025–2026)

Métrique	RL+ARIMA	Baseline	Gain
R^2 (coefficient de détermination)	**0,893**	—	—
MAE (μg/m^3)	**3,456**	11,647	−70,3 %
RMSE (μg/m^3)	**5,088**	—	—
Pics > 35 μg/m^{3}correctement prédits	**79,6 %**	—	—

Source : Auteurs à partir des données de lÁPI Open-Meteo.

La baseline naïve consiste à prédire la moyenne historique nationale pour chaque observation. Le modèle hybride réduit l'erreur absolue moyenne de 70,3 %, passant de 11,647 à 3,456 μg/m^3. Cette amélioration est robuste : elle est obtenue sur des données de test strictement postérieures à la période d'entraînement.

4.2 Analyse graphique des prédictions

La figure 4.1 présente deux diagnostics complémentaires. Le nuage de points (panneau gauche) montre une forte concentration des observations autour de la diagonale de prédiction parfaite pour les valeurs inférieures à 60 μg/m^3. On observe, comme attendu pour tout modèle de régression, une légère sous-estimation des valeurs extrêmes (> 80 μg/m^3), phénomène de régression vers la moyenne inhérent à la régression linéaire. La timeline (panneau droit) confirme la qualité du suivi de la dynamique temporelle à Yaoundé en 2025, avec une bonne capture des épisodes saisonniers.

Figure 4.1. Prédictions vs observations — modèle hybride RL+ARIMA ($R^2 = 0{,}893$, MAE = 3,456 μg/m^3)

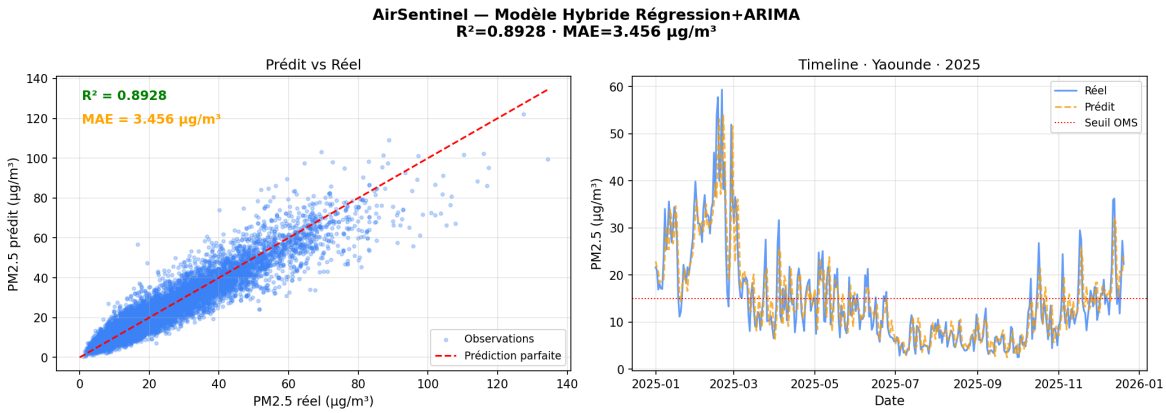

Source : Auteurs à partir des données de l'API Open-Meteo.

4.2.1 Cas de validation : Bertoua, 13 février 2025

Le 13 février 2025, un pic de pollution exceptionnel a été enregistré à Bertoua dans la zone équatoriale, en pleine saison des feux de brousse. Le $PM_{2.5}$ observé a atteint **110,3 μg/m^3**, soit 7,4 fois le seuil OMS. Le modèle hybride a produit une prédiction de **101,8 μg/m^3**, avec une erreur absolue de seulement 8,4 μg/m^3(7,6 % d'erreur relative). Le niveau d'alerte CRITIQUE a été correctement maintenu, permettant l'émission d'une recommandation sanitaire appropriée.

4.3 Diagnostic des résidus

4.3.1 Distribution et structure temporelle

La figure 4.2 présente trois diagnostics des résidus du modèle. La distribution (panneau gauche) est centrée en zéro avec une légère leptokurtose, confirmant la présence de quelques observations extrêmes mal captées. Le QQ-Plot (panneau central) révèle des queues lourdes, cohérentes avec la nature des épisodes de pollution exceptionnelle. La série temporelle des résidus (panneau droit) ne présente pas de tendance systématique, indiquant l'absence de biais temporel dans les prédictions.

Figure 4.2. Diagnostic des résidus — distribution, QQ-Plot et série temporelle

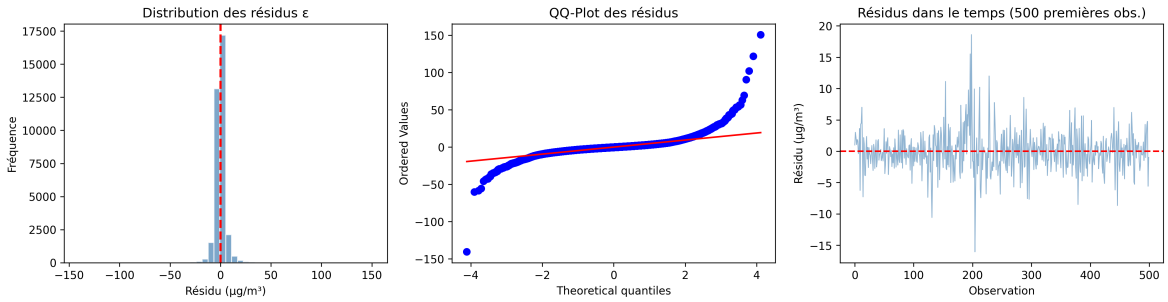

Source : Auteurs à partir des données de l'API Open-Meteo.

4.3.2 Autocorrélation des résidus ARIMA

La figure 4.3 présente les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) des résidus ARIMA pour Yaoundé. L'ensemble des coefficients restent dans les bandes de confiance à 95 % pour les lags supérieurs à 1, confirmant que les résidus se comportent comme un bruit blanc. Ce résultat est corroboré par le test de Ljung-Box ($p > 0{,}05$) sur toutes les zones climatiques, validant l'adéquation du modèle ARIMA.

Figure 4.3. ACF et PACF des résidus ARIMA — Yaoundé (zone équatoriale)

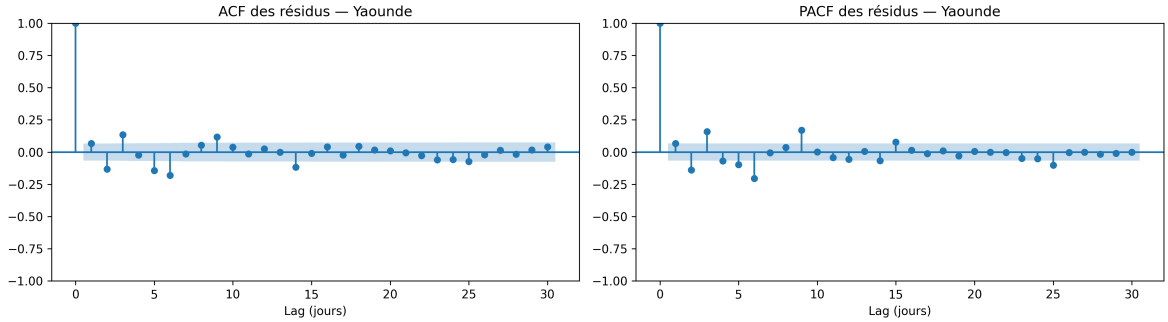

Source : Auteurs à partir des données de l'API Open-Meteo.

4.4 Interprétabilité SHAP

4.4.1 Importance globale des variables

La figure 4.4 présente l'importance SHAP moyenne des variables sur l'ensemble du dataset de test. Trois enseignements principaux se dégagent. Premièrement, les variables de mémoire du $PM_{2.5}$ dominent nettement le classement : la moyenne mobile sur 7 jours (`pm2_5_moy_7j`, importance $\approx 7{,}0$), suivie du lag à 1 jour (`pm2_5_lag_1j`, $\approx 4{,}5$) et du lag à 3 jours (`pm2_5_lag_3j`, $\approx 3{,}4$). Ce résultat confirme la forte persistance temporelle de la pollution atmosphérique au Cameroun et valide le choix de l'approche hybride RL+ARIMA. Deuxièmement, les précipitations (`precipitation_hours`) et l'évapotranspiration (`et0_fao_evapotranspiration`) apparaissent dans le top 6, confirmant leur rôle de régulation atmosphérique. Troisièmement, la variable temporelle `jour_annee` est la plus contributive parmi les features de date, capturant les effets saisonniers.

Figure 4.4. Importance SHAP moyenne des variables — AirSentinel Cameroun

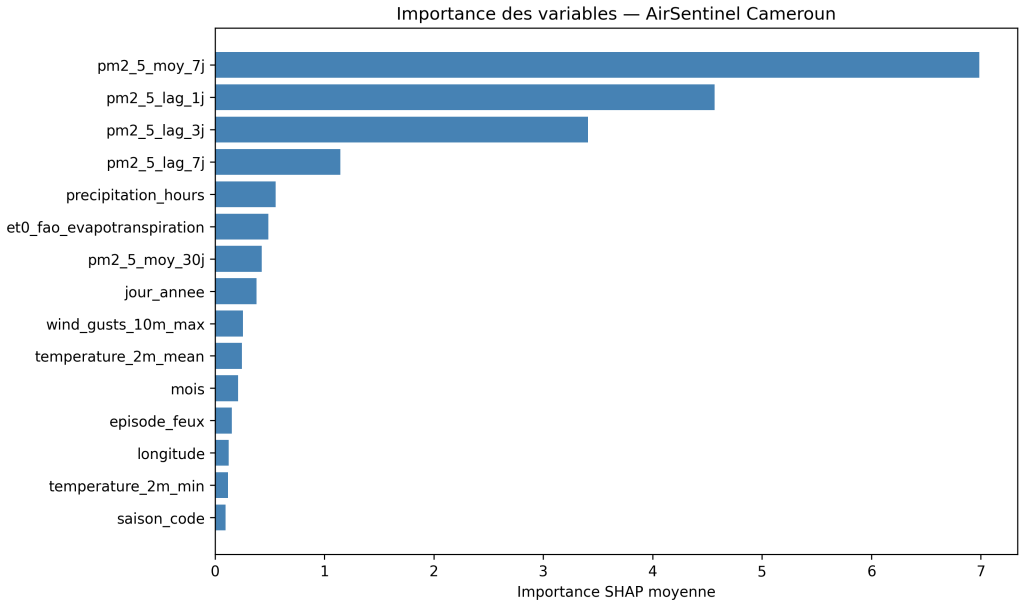

Source : Auteurs à partir des données de l'API Open-Meteo.

4.4.2 Analyse directionnelle

La figure 4.5 présente le beeswarm plot SHAP, qui combine l'importance et la direction de l'impact de chaque variable. Des valeurs élevées de `pm2_5_lag_1j` (points rouges, côté droit) génèrent des valeurs SHAP fortement positives (jusqu'à +65), traduisant la persistance des épisodes. Inversement, des précipitations élevées (points rouges de `precipitation_hours`) ont un impact SHAP négatif, cohérent avec le rôle de lessivage atmosphérique des pluies. La dispersion du nuage pour `episode_feux` confirme le caractère impulsionnel et ponctuel de ces événements.

Figure 4.5. Beeswarm plot SHAP — direction et magnitude des contributions

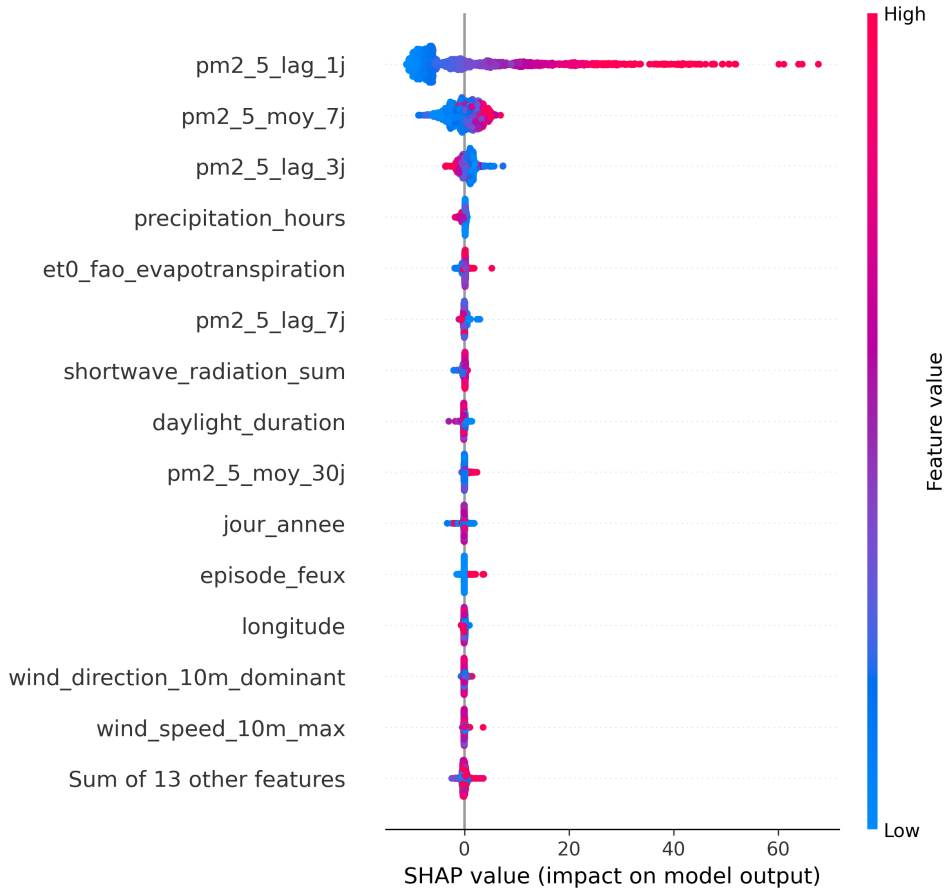

Source : Auteurs à partir des données de l'API Open-Meteo.

4.4.3 Analyse par zone climatique

La figure 4.6 compare le top 3 des variables SHAP entre les trois zones climatiques INS. La hiérarchie `moy_7j` > `lag_1j` > `lag_3j` est stable entre les zones, suggérant que la mémoire temporelle constitue le déterminant commun principal, indépendamment du contexte géographique. On note toutefois des importances absolues légèrement plus élevées dans la zone soudano-sahélienne, cohérentes avec la plus forte persistance des épisodes d'harmattan.

Figure 4.6. Top 3 des variables SHAP par zone climatique INS Cameroun (2019)

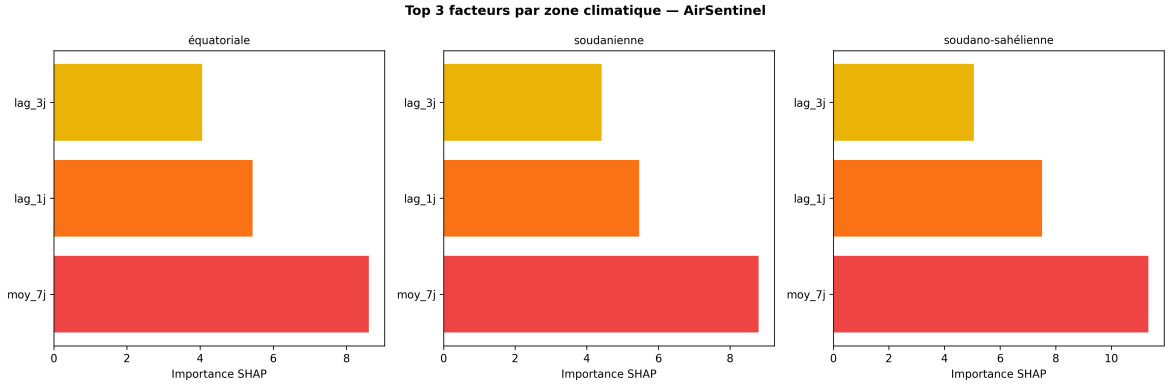

Source : Auteurs à partir des données de l'API Open-Meteo.

5. Architecture de la plateforme

5.1 Vue d'ensemble

AirSentinel Cameroun est une plateforme multi-composants comprenant un dashboard Streamlit (6 blocs fonctionnels, bilingue FR/EN), une API FastAPI publique (7 endpoints REST avec documentation Swagger), une application mobile progressive (PWA, Antigravity, mode hors-ligne) et un pipeline automatisé GitHub Actions. L'ensemble est hébergé gratuitement, avec un coût d'exploitation nul.

5.2 Dashboard Streamlit

Tableau 5.1. Description des 6 blocs fonctionnels du dashboard

Bloc	Titre	Fonctionnalités principales
1	Carte interactive	Carte Plotly des 40 villes ; colorisation selon $PM_{2.5}$; prédictions J/J+1/J+2 ; filtrage multiselect par région ; zoom automatique sur la zone sélectionnée.
2	KPIs nationaux	6 indicateurs clés ($PM_{2.5}$, IRS, villes dépassant l'OMS, polluant dominant, tendance annuelle, nombre d'observations) ; graphiques de tendance mensuelle et de saisonnalité avec lignes seuil OMS et seuil contextuel camerounais.
3	Prédictions 72h	Prédictions J/J+1/J+2 par ville sélectionnée ; performances du modèle ; simulateur météo interactif permettant d'explorer l'effet de chaque feature ; jauge IRS Plotly native.
4	Alertes	Système d'alertes visuelles par niveau ; recommandations selon le profil utilisateur ; tableau des populations vulnérables (enfants, seniors, asthmatiques, agriculteurs).
5	Décision sanitaire	Tableau de bord par ville combinant jauge IRS, seuil OMS et seuil contextuel camerounais (p90) ; export PDF (rapport sanitaire A4) et CSV.
6	Profil climatique	Analyse comparative des 3 zones INS ; insights saisonniers ; recommandations par profil ; comparaison des indicateurs inter-zones.

Source : Auteurs à partir des données de lÁPI Open-Meteo.

5.3 API FastAPI

Tableau 5.2. Endpoints de l'API publique AirSentinel

Méthode	Endpoint	Description
GET	`/`	Informations API, version, statistiques dataset
GET	`/villes`	40 villes : coordonnées, région, zone climatique
GET	`/regions`	10 régions et zones climatiques INS
GET	`/data/{ville}`	Dernières données observées pour une ville
GET	`/predict/{ville}`	Prédictions J/J+1/J+2 avec intervalle de confiance
GET	`/alerte/{ville}`	Niveau d'alerte IRS et recommandations par profil
GET	`/national`	Résumé national et top 5 des villes les plus polluées

Source : Auteurs à partir des données de lÁPI Open-Meteo.

5.4 Seuils contextuels camerounais

En complément du seuil OMS absolu ($15\,\mu g/m^3$), des seuils contextuels calibrés sur le percentile 90 historique par ville ont été calculés à partir des données 2022–2026 et sauvegardés dans `seuils_contextuels.pkl`. Ces seuils permettent de détecter les jours anormalement pollués pour chaque ville, indépendamment des standards internationaux.

Il est important de distinguer les deux référentiels. Le seuil OMS répond à la question *« ce niveau est-il dangereux pour la santé ? »* selon les critères épidémiologiques internationaux. Le seuil contextuel p90 répond à *« ce jour est-il anormalement pollué pour cette ville par rapport à son historique ? »*. Ces deux indicateurs sont complémentaires : une ville chroniquement polluée (Extrême-Nord) dépasse constamment le seuil OMS mais n'excède son p90 local que lors de pics réellement exceptionnels.

6. Conclusion et perspectives

6.1 Bilan

AirSentinel Cameroun démontre la faisabilité d'un système complet de surveillance et de prédiction de la qualité de l'air pour un pays en développement, à coût nul. Les trois objectifs stratégiques sont atteints : 40 villes surveillées en temps quasi-réel (OS1) ; modèle hybride atteignant $R^2 = 0{,}893$ et MAE $= 3{,}456\,\mu\text{g/m}^3$avec réduction de 70,3 % de l'erreur (OS2) ; plateforme complète avec IRS, seuils contextuels, recommandations et exports (OS3). L'analyse SHAP confirme la cohérence physique du modèle, dont les variables les plus contributives correspondent aux mécanismes atmosphériques documentés dans la littérature.

6.2 Limitations

Trois limitations principales doivent être soulignées. Premièrement, les données Open-Meteo sont des réanalyses numériques et non des mesures directes de stations au sol ; la disponibilité de mesures terrain améliorerait la précision sur les valeurs extrêmes. Deuxièmement, la régression linéaire sous-estime les pics extrêmes ($> 80\,\mu\text{g/m}^3$) par régression vers la moyenne, visible sur le QQ-Plot des résidus. Troisièmement, les seuils contextuels p90 par ville définissent les pics locaux mais ne reflètent pas l'exposition chronique : une ville comme Mokolo (p90 $= 62{,}8\,\mu\text{g/m}^3$) dispose d'un seuil élevé qui masque partiellement son niveau de pollution chronique élevé dans la comparaison inter-villes.

6.3 Perspectives

Les développements envisagés portent sur cinq axes. L'intégration de données satellites (Sentinel-5P TROPOMI, MODIS MAIAC) permettrait de valider et de compléter les données Open-Meteo. Le recours à des modèles d'apprentissage profond (LSTM, Temporal Fusion Transformer) améliorerait la capture des dépendances à long terme et la prédiction des pics extrêmes. L'architecture modulaire du pipeline permet une extension immédiate à d'autres pays d'Afrique centrale. Un déploiement institutionnel en partenariat avec le Ministère de la Santé Publique du Cameroun et l'ONACC permettrait d'intégrer les alertes dans les systèmes d'information sanitaire nationaux. Enfin, un réseau de surveillance transfrontalier serait pertinent pour les épisodes d'harmattan affectant simultanément plusieurs pays du bassin du lac Tchad.

Références bibliographiques

Barker P.A. et al. (2020)
Barker, P.A., Allen, G., Gallagher, M. et al. Carbon monoxide and aerosol loading associated with biomass burning in tropical Africa. *Atmospheric Chemistry and Physics*, 20(8), 4987–5005.

Box G.E.P. et Jenkins G.M. (1976)
Box, G.E.P., Jenkins, G.M. *Time Series Analysis : Forecasting and Control*. Holden-Day, San Francisco.

Chen J. et Hoek G. (2020)
Chen, J., Hoek, G. Long-term exposure to PM and all-cause and cause-specific mortality : A systematic review and meta-analysis. *Environment International*, 143, 105974.

Gordon T. et al. (2023)
Gordon, T., Ristovski, Z., Cope, M. et al. Biomass burning and atmospheric particulate matter in sub-Saharan Africa. PMC9884662.

INS Cameroun (2019)
Institut National de la Statistique du Cameroun. *Annuaire Statistique du Cameroun 2019*. Yaoundé : INS.

IPCC (2014)
Intergovernmental Panel on Climate Change. *Fifth Assessment Report (AR5) — Working Group II : Impacts, Adaptation and Vulnerability*. Cambridge University Press.

Knippertz P. et Todd M.C. (2008)
Knippertz, P., Todd, M.C. Mineral dust aerosols over the Sahara : Meteorological controls on emission and transport. *Reviews of Geophysics*, 50(1).

Lundberg S.M. et Lee S.-I. (2017)
Lundberg, S.M., Lee, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems* (NeurIPS 2017), 30.

Schepanski K. et al. (2007)
Schepanski, K., Tegen, I., Todd, M.C. et al. Saharan dust transport and deposition towards the tropical northern Atlantic. *Geophysical Research Letters*, 34(24).

WHO (2021)
World Health Organization. *WHO Global Air Quality Guidelines : Particulate matter ($PM_{2.5}$ and PM_{10}), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Geneva : WHO. NCBI NBK574591.